Projet Big Data

Objectif général

Développer une solution Big Data complète utilisant Hadoop, YARN, MapReduce, Hive, et HBase, pour gérer un système d'orientation nationale basé sur un dataset massif simulant des candidats, leurs notes, leurs choix et leurs affectations.

PARTIE A — Génération du Dataset (obligatoire)

Vous devez générer un *dataset massif* (minimum 5000 lignes) composé de :

1) Candidats.txt

Chaque ligne contient :

Num_CIN Nom Prenom Filiere

- Filière ∈ {MP, PC}

Une fonction creation_liste_candidats() doit générer automatiquement ces données.

2) Notes.txt

Chaque ligne contient :

Num_CIN Analyse Algèbre Physique Chimie Informatique STA Français Anglais

Notes entre 0 et 20.

Une fonction creation_notes() génère automatiquement ces notes.

3) Choix (3 choix par candidat)

Format :

Num_CIN Choix1 Choix2 Choix3

Une fonction creation_choix() génère ce fichier ou dictionnaire.

4) Dictionnaire des filières

filiere = { code_filiere : [code_ecole, capacité] }

Exemple :

{"MP" : ["E101", 200],

"PC" : ["E205", 150]}

Créer via la fonction creation_filiere().

© 2025 Caplogy. All rights reserved.

PARTIE B — Stockage Big Data

5) Stockage dans HDFS

Créer un dossier /orientation puis importer tous les fichiers générés.

PARTIE C — Traitement MapReduce

6) Calcul du Score FG via MapReduce

Formule globale :

FG = Analyse*8 + Algèbre*6 + Physique*8 + Chimie*6 + Informatique*6 + STA*4 + Français*3 + Anglais*3

Utiliser un job MapReduce pour :

- Lire Candidats.txt + Notes.txt
- Calculer FG
- Trier les candidats par FG décroissant
- Générer Rang.txt :Num_CIN FG Rang

Fonction : creation_rang().

PARTIE D — Analyse Hive

7) Charger les données dans Hive

Créer des tables externes pour :

- candidats
- notes
- rang
- choix
- resultats

8) Requêtes à exécuter

- Moyenne par matière
- Moyenne des scores FG
- Distribution des filières MP vs PC
- TOP 10 meilleurs scores
- Statistiques des notes

© 2025 Caplogy. All rights reserved.

PARTIE E — Traitement NoSQL (HBase)

9) Stockage dans HBase

- Table FILIERE (clé = filière)
- Table CHOIX (clé = CIN)
- Table RESULTATS (clé = CIN)

10) Calcul final des affectations

Méthode :

1. Parcourir Rang.txt (ordre décroissant)
2. Pour chaque candidat :
    - tester choix1
    - sinon choix2
    - sinon choix3
3. Décrémenter la capacité dans HBase
4. Générer Resultats.txt :

Num_CIN Code_Filiere_Affectée

Fonction : creation_resultat().

PARTIE F — Visualisation

11) Tracer les graphiques

À l'aide de Python (matplotlib) :

- Histogramme des notes pour chaque matière
- Répartition MP vs PC
- Courbe des moyennes
- Histogramme des scores FG

Fonction : trace_courbes().

PARTIE G — Programme Principal

Créer un **menu interactif** permettant d'exécuter toutes les fonctions. Exemple :

© 2025 Caplogy. All rights reserved.

1. Générer dataset candidats
2. Générer notes
3. Générer filières
4. Calculer rang via MapReduce
5. Générer choix
6. Générer résultats d'orientation
7. Visualiser statistiques
8. Charger et analyser via Hive
9. Quitter

▧ 2 — COMPTE-RENDU (MODÈLE DE RAPPORT POUR L'ÉTUDIANT)

Le rapport doit contenir :

1. Introduction

- Objectif du projet
- Technologies utilisées

2. Création du Dataset

- Méthodologie
- Taille du dataset
- Structure des fichiers
- Exemple de lignes
- Difficultés rencontrées

3. Stockage HDFS

- Commandes utilisées
- Structure du répertoire /orientation
- Screenshots

4. Traitement MapReduce

- Principe du Mapper
- Principe du Reducer
- Fusion des fichiers
- Calcul du score FG

© 2025 Caplogy. All rights reserved.

- Logique du tri
- Capture YARN du job terminé

5. Analyse Hive

- Script de création des tables externes
- Requêtes exécutées
- Résultats des analyses
- Interprétation

6. Base NoSQL HBase

- Modèle de données
- Commandes HBase
- Exemple de scans
- Mise à jour des capacités

7. Calcul final des affectations

- Explication de l'algorithme
- Screenshots HBase après décrémentation
- Extrait de Resultats.txt

8. Visualisations

Inclure :

- Histogrammes
- Courbes
- Interprétation

9. Conclusion

- Bilan
- Limites
- Propositions d'amélioration

3 — GRILLE D'ÉVALUATION (20 points)

© 2025 Caplogy. All rights reserved.

Critère	Points
1. Génération dataset	**4 pts**
— Candidats (1)	
— Notes (1)	
— Choix (1)	
— Qualité & volumétrie (1)	
2. HDFS	**2 pts**
— Import (1)	
— Organisation (1)	
3. MapReduce — Score FG & Rang	**4 pts**
— Mapper (1)	
— Reducer (1)	
— Calcul exact FG (1)	
— Génération Rang.txt (1)	
4. Hive	**3 pts**
— Tables externes (1)	
— Requêtes analytiques (1)	
— Qualité des résultats (1)	
5. HBase	**3 pts**
— Table filières (1)	
— Table choix (1)	

© 2025 Caplogy. All rights reserved.

— Résultats orientation (1)	
6. Visualisation	**2 pts**
— Graphiques matières (1)	
— Bonne présentation (1)	
7. Menu principal	**1 pt**
8. Rapport	**1 pt**
Total	**20 pts**

© 2025 Caplogy. All rights reserved.